

Riconoscimento di strumenti musicali su IRMAS con una CNN multi-input

1 Sommario

Questo progetto affronta il riconoscimento di strumenti musicali sul benchmark **IRMAS** con un'architettura progettata ad hoc, **MultiBranchNet**: una CNN multi-input in cui quattro rappresentazioni dello stesso audio (log-mel, CQT, waveform grezza, chroma) attraversano rami dedicati, fusi in una testa di classificazione multi-label a 11 strumenti. I rami mel e CQT riusano backbone ResNet18 pre-addestrate su ImageNet (transfer learning "spettrogramma come immagine"); i rami waveform e chroma sono addestrati da zero.

Risultati sul test set ufficiale (polifonico, multi-label), con aggregazione dei punteggi di finestra tramite **90° percentile** (p90):

Metrica	Valore
micro-F1	0,607
macro-F1	0,506
micro precision / recall	0,713 / 0,528
micro-F1 di validazione (clip mono-strumento)	0,845

Il micro-F1 di **0,607** colloca il sistema nella fascia bassa dei metodi pre-addestrati su audio, pur partendo da un transfer da ImageNet. Il risultato dipende in modo determinante dall'operatore con cui i punteggi delle finestre di 3s vengono fusi in una predizione per clip: sono stati provati anche la media (**mean**, micro-F1 **0,533**) e il massimo (**max**, **0,593**), ma il 90° percentile li supera entrambi. Con **p90** la soglia ottimizzata in validazione (0,40) risulta quasi ottimale anche sul test, chiudendo il divario di calibrazione che affligge la media.

2 Il problema e il dataset

IRMAS (Bosch et al., MTG-UPF) è il benchmark di riferimento per il riconoscimento dello strumento predominante:

- **Training**: 6.705 clip da 3 s, ciascuna con **un solo** strumento etichettato (11 classi: violoncello, clarinetto, flauto, chitarra acustica, chitarra elettrica, organo, pianoforte, sax, tromba, violino, voce).
- **Test**: 2.874 estratti da 5–20 s di brani reali, **polifonici e multi-label** (in media 1,71 strumenti per clip).

L'asimmetria train mono-strumento / test polifonico è la difficoltà centrale del benchmark: il modello impara da esempi "puliti" ma viene valutato su missaggi reali. Il compito è quindi

formulato come **classificazione multi-label**: 11 uscite sigmoidee indipendenti addestrate con binary cross-entropy, non una softmax a scelta singola.

3 Architettura




Figura 1: Architettura di MultiBranchNet.

Le scelte principali:

- **Spettrogrammi come immagini.** Log-mel e CQT sono matrici tempo-frequenza; replicando il canale mono su 3 canali si riusa senza modifiche la prima convoluzione di ResNet18 pre-addestrata su ImageNet. Una BatchNorm d'ingresso per ramo adatta le statistiche degli spettrogrammi a quelle attese dalla rete.
- **Rappresentazioni complementari.** Il log-mel (128 bande) modella il timbro; la CQT (84 bin, 7 ottave $\times$ 12 semitoni) ha risoluzione allineata alle note musicali; la waveform grezza conserva fase e attacchi che gli spettrogrammi perdono; il chroma (12 classi di altezza) codifica il contenuto armonico.
- **Fusion late.** Gli embedding dei rami attivi sono concatenati e classificati da un MLP con dropout; uscite = 11 logit indipendenti (sigmoid a inferenza).

4 Pipeline

Per il preprocessing, uno script dedicato converte ogni clip di training (22.050 Hz mono) nelle quattro rappresentazioni e le salva in **.npz float16**, insieme alle statistiche di normalizzazione (media/deviazione per feature) calcolate **sul solo training set**. Le stesse funzioni di estrazione sono riusate in valutazione, garantendo coerenza train/test.

Augmentation. SpecAugment (mascheramento di bande tempo/frequenza) su mel e CQT; **mixup** a livello di batch con lo stesso coefficiente λ applicato coerentemente a tutti gli input e ai target. Il mixup ha anche un ruolo concettuale: fondendo due clip mono-strumento crea esempi artificialmente *bi-strumentali*, avvicinando il training alla natura polifonica del test.

Addestramento in due fasi:

1. *Warmup* (3 epoche): backbone ImageNet congelate, si addestrano testa e rami da zero (LR $1e-3$);
2. *Finetuning* (25 epoche): tutto scongelato con LR discriminativi (backbone $5e-5$, resto $5e-4$), cosine decay, early stopping su micro-F1 di validazione (mai scattato), checkpoint del migliore.

Valutazione (protocollo IRMAS ufficiale). Ogni clip di test è scomposta in finestre da 3 s con hop 1 s; i punteggi sigmoidei per finestra sono aggregati con il **90° percentile**; la binarizzazione usa una **soglia ottimizzata sulla validazione** (risultata 0,40). Metriche: precision/recall/F1 micro e macro, più F1 per classe.

5 Risultati

5.1 Addestramento




Figura 2: Curva di addestramento: loss BCE (sinistra) e micro-F1 di validazione (destra); l'area ombreggiata segna la fase di warmup.

La loss scende monotonicamente e il micro-F1 di validazione sale da 0,28 a **0,845** in 28 epoche, senza sovradattamento visibile (le difese: warmup a backbone congelate, weight decay, dropout, SpecAugment, mixup). Il salto più netto (0,48 $\rightarrow$ 0,60) coincide con lo sblocco delle backbone all'inizio del finetuning.

5.2 Test set: quadro globale

	precision	recall	F1
micro	0,713	0,528	0,607
macro	0,575	0,486	0,506

Il profilo è bilanciato: precision 0,71 e recall 0,53. È merito dell'aggregazione **p90**: la media (**mean**) dava invece un profilo fortemente sbilanciato (precision 0,89, recall 0,38, micro-F1 0,533), troppo prudente sui missaggi.




Figura 3: F1 per classe sul test set, alla soglia ottimizzata in validazione.

5.3 Test set: per classe

Strumento	Clip train	Presenze test	P	R	F1
voce (voi)	778	1043	0,95	0,86	0,90
sax	626	325	0,70	0,85	0,77
violino (vio)	580	211	0,51	0,64	0,56
chit. acustica (gac)	637	535	0,75	0,44	0,56
tromba (tru)	577	166	0,52	0,58	0,55
chit. elettrica (gel)	760	941	0,79	0,38	0,52
pianoforte (pia)	721	994	0,89	0,35	0,50
flauto (flu)	451	163	0,43	0,52	0,47
organo (org)	682	359	0,50	0,35	0,41
violoncello (cel)	388	111	0,23	0,27	0,25
clarinetto (cla)	505	61	0,07	0,12	0,08

Tre osservazioni:

1. **Il timbro conta più della quantità di dati.** Voce e sax dominano grazie a firme spettrali inconfondibili (0,90 e 0,77), il sax con recall altissimo (0,85). Il pianoforte, pur avendo tantissimi esempi (721 in train, 994 nel test), si ferma a 0,50 con profilo $P=0,89 / R=0,35$: lo riconosce bene solo quando è in primo piano (precision alta), ma nei brani reali suona spesso in accompagnamento, a volume più basso e coperto dagli strumenti solisti. La coppia $P=0,89 / R=0,35$ resta precision-heavy: quando dice "piano" raramente sbaglia, ma manca due presenze su tre.
2. **Il clarinetto è la classe più debole (0,08):** con soli 61 casi di test e un timbro facilmente mascherato resta al fondo — ma non è più a zero come con la media. Non è mancanza di dati (505 clip di training, più di violoncello e flauto).
3. **Il macro-F1 (0,506) è trascinato giù dalla coda** (violoncello 0,25, clarinetto 0,08, organo 0,41), mentre il micro (0,607) riflette le classi frequenti e ben riconosciute. Il divario micro/macro misura lo sbilanciamento di difficoltà tra classi.

6 Analisi

6.1 Calibrazione della soglia

La soglia di decisione è ottimizzata sulla validazione, fatta di clip **mono-strumento** (una sola finestra da 3 s per clip). Con l'aggregazione **p90** il punteggio per clip resta sulla scala di una singola finestra confidente, quindi la soglia tarata in validazione (0,40) si trasferisce bene al test **polifonico**.




Figura 4: Analisi di sensibilità alla soglia di decisione: micro/macro-F1 al variare del taglio.

L'analisi di sensibilità lo conferma:

Soglia	micro-F1	macro-F1
0,50 fissa	0,599	0,499
0,40 (ottimizzata su validazione — usata)	0,607	0,506
0,35 (ottimo a posteriori sul test)	0,611	0,512

La soglia scelta in validazione (0,40) dista appena **+0,4 punti** di micro-F1 dall'ottimo a posteriori (0,611 @ 0,35): la calibrazione **non è più un collo di bottiglia**. È un cambiamento netto rispetto all'aggregazione per media, dove la stessa soglia 0,40 rendeva solo 0,533 contro un ottimo a posteriori di 0,608 — un divario di +7,5 punti che era, in gran parte, un artefatto del mean-pooling.

6.2 Nota sull'aggregazione temporale

L'operatore con cui i punteggi delle finestre da 3s vengono fusi in una predizione per clip è la leva più importante dell'intera valutazione. A parità di modello e di soglia (0,40) sono stati confrontati tre operatori:

Aggregazione	micro-F1	macro-F1	micro-P	micro-R
mean (media)	0,533	0,439	0,886	0,381
max (massimo)	0,593	0,495	0,581	0,606
p90 (90° percentile, scelto)	0,607	0,506	0,713	0,528




Figura 5: Confronto delle aggregazioni temporali (mean / max / p90) alla soglia 0,40 fissa.

La media **diluisce** gli strumenti presenti solo in poche finestre su venti, schiacciandoli sotto soglia (recall 0,38). Il massimo li recupera (recall 0,61) ma è sensibile ai picchi spuri, sacrificando precisione. Il **90° percentile** — un "massimo robusto", proporzionale alla durata — combina il recall alto con una precisione elevata (0,71), ed è la scelta adottata; il **top-3** (media delle 3 finestre migliori) è praticamente equivalente (0,605).

6.3 Dove nascono i falsi positivi

Per ogni falso positivo, la matrice seguente mostra quali strumenti erano *realmente* presenti nella clip (le righe sono lo strumento erroneamente predetto; valori = frazione dei suoi FP):

Le confusioni raccontano storie musicalmente sensate:

- I falsi positivi di **sax** e **tromba** cadono in gran parte su clip che contengono **pianoforte** (0,41 e 0,52): contesti jazz in cui il piano accompagna un solista.
- Le due **chitarre si scambiano a vicenda**: i FP di acustica cadono su clip con l'elettrica (0,50) e i FP di pianoforte su clip con l'acustica (0,43) — timbri di corde pizzicate/percosse facilmente confusi.
- **Chitarra elettrica** e **organo** sbagliano soprattutto su clip con **voce** (0,39 e 0,36): contesti pop/gospel dove voce, tastiere e chitarra si sovrappongono spettralmente.

6.4 Confronto con la letteratura

Approccio	micro-F1	macro-F1
Bosch et al. 2012 (feature ingegnerizzate + SVM)	~0,50	~0,43
MultiBranchNet (questo lavoro, aggregazione p90)	0,607	0,506
CNN su audio pre-addestrate (es. PANNs finetuning)	~0,60–0,65	~0,52–0,58
Stato dell'arte	~0,65–0,70	~0,58–0,63

Con l'aggregazione **p90** il modello (0,607) **raggiunge** la fascia bassa dei sistemi pre-addestrati su audio, pur partendo da un transfer ImageNet (immagini naturali) anziché da grandi corpora audio — notevole dato il prior meno adatto. Resta sotto lo stato dell'arte, distanza colmabile con backbone audio-native.




Figura 6: Attribuzione dei falsi positivi: per ogni strumento erroneamente predetto, gli strumenti realmente presenti nella clip.

7 Limiti e sviluppi futuri

1. **Calibrazione fine:** il passaggio a p90 ha già recuperato gran parte del divario di calibrazione; restano da esplorare le soglie per-classe e la taratura della soglia su una validazione resa polifonica (mix sintetici di coppie di clip) anziché su clip mono-strumento.
2. **Ablation study per ramo:** quantificare il contributo di CQT, waveform e chroma rispetto al solo mel — in particolare verificare l’ipotesi che il chroma sia ridondante rispetto alla CQT.
3. **Classi deboli:** pesi di classe nella loss o oversampling per la coda (clarinetto, violoncello, organo).
4. **Transfer audio-nativo:** sostituire ImageNet con backbone pre-addestrate su audio per colmare il divario residuo con lo stato dell’arte.

Riferimenti

- Bosch, Janer, Fuhrmann, Herrera — *A comparison of sound segregation techniques for pre-dominant instrument recognition in musical audio signals*, ISMIR 2012 (dataset IRMAS).
- He, Zhang, Ren, Sun — *Deep Residual Learning for Image Recognition*, 2015.

- Park et al. — *SpecAugment*, 2019.
- Zhang et al. — *mixup: Beyond Empirical Risk Minimization*, 2017.
- Kong et al. — *PANNs: Large-Scale Pretrained Audio Neural Networks*, 2020 (riferimento di confronto).